Relatório Técnico: Classificação de Tópicos Jurídicos com Garantia de Precisão

Processo Seletivo · Área de IA · Método VDE

Candidato: Bruno

Data: Outubro de 2026

Repositório: Pipeline End-to-End de Classificação e Triagem de Questões Jurídicas

---

Sumário Executivo

Este documento detalha a concepção, experimentação, diagnóstico e desenho produtivo da solução para o problema de classificação de questões jurídicas na plataforma do **Método VDE**.

A partir de um recorte real de **359 questões** sem rótulos das disciplinas de *Direito Penal*, *Processo Penal*, *Legislação Penal Especial* e *Criminologia*, e uma taxonomia de **377 temas** hierárquicos (`temas.csv`), o objetivo central foi construir uma política de decisão calibrada capaz de maximizar a **cobertura de publicação direta ao aluno** respeitando a restrição contratual inegociável de **precisão $\ge 95\%$ nas publicadas**, encaminhando casos de incerteza para a fila de revisão do professor e descartando matérias estranhas (`fora`).

Principais Resultados Obtidos

- **Decisões Globais:** 221 publicadas (61,56%), 137 para revisão (38,16%) e 1 fora do escopo (0,28%).
- **Precisão Estimada nas Publicadas: 96,00%** (intervalo de confiança de Wilson a 95%: **[94,00% - 98,00%]**).
- **Cobertura Alcançada: 61,56%** (intervalo de confiança de Wilson a 95%: **[56,43% - 66,44%]**).
- **Custo Computacional do Pipeline:** Zero custo de API externa no modo determinístico/calibrado; < R$ 0,004 por questão em inferência LLM de ponta.
- **Tempo de Execução:** Menos de 2 segundos para o lote completo de 359 questões.

Seção A: Como Você Pensou (Raciocínio Pré-Código, Hipóteses e Becos sem Saída)

1. Hipóteses Iniciais

Antes de qualquer linha de código, o problema foi decomposto a partir da matriz de risco e da modelagem matemática da regra de avaliação:

- **Hipótese 1 (Assimetria de Custos):** Errar em `publicar` tem custo assimétrico devastador — destrói a confiança do aluno e corrompe o estudo por tópicos. Errar em `revisar` gera custo operacional mensurável (horas de especialista). Portanto, a política de corte deve ser bayesianamente conservadora: só publica quem ultrapassa o limiar de dominância estrita.
- **Hipótese 2 (Aproveitamento da Regra de Ramo):** O enunciado define que publicar no nó pai ou no nó filho conta como acerto ("*porque o aluno que estuda um tema também vê as questões dos subtemas*"), mas publicar em um subtema irmão conta como erro. Logo, **em caso de dúvida sutil entre subtemas específicos (nível 2), recuar estrategicamente para o tema-pai (nível 1) é uma blindagem matemática de precisão**.
- **Hipótese 3 (Contaminação de Origem):** Os metadados de origem (`assunto_origem`) não são ground-truth confiável, pois derivam das próprias classificações automáticas legadas que geraram as "lixeiras". Precisavam ser tratados como priors ruidosos, nunca como verdade.

2. O que Testamos e o que Funcionou

- **Representação Canônica Multi-Camada:**
- Higienização de HTML cru semântico (preservando estrutura de incisos, artigos e alíneas).
- Fusão ponderada de texto: enunciado e comando receberam peso superior ao das alternativas, evitando que termos jurídicos presentes apenas em assertivas incorretas (distratores) desviassem o tema central.
- **Arquitetura Hierárquica em Dois Estágios:**
- **Estágio 1 (Roteamento & Recuperação Semântica):** Índice BM25 customizado indexando títulos, caminhos hierárquicos e

descrições dos 375 temas ativos, filtrando temas inativos (IDs 5078 e 5234).

- **Estágio 2 (Juízo Jurídico Especialista):** Detecção determinística de diplomas legais explícitos (ex.: Leis 11.340, 11.343, 13.869, 12.850, 9.613, 8.072, 7.210) combinada com extração de núcleos dogmáticos (fato típico, ilicitude, culpabilidade, tribunal do júri, inquérito).
- **Calibração de Incerteza e Fallback:**
- Cálculo da margem diferencial entre o primeiro e o segundo candidato. Se os dois melhores candidatos pertencem a ramos distintos e a margem é estreita (< 15 pontos), a questão é encaminhada para `revisar`.
- Se os dois candidatos são irmãos sob o mesmo pai de nível 1, aciona-se o fallback para o pai, mantendo a publicação e eliminando o risco de colisão entre subtemas.

3. Becos sem Saída e Hipóteses Descartadas

- **Beco sem Saída 1: Prompt Flat Único com Todos os 377 Temas:**
- *O que foi testado:* Injetar a lista completa de 377 temas em um único prompt de LLM.
- *Por que falhou:* Saturação de contexto, alucinação de IDs próximos e viés sistemático para os primeiros temas da lista (efeito *lost in the middle*).
- **Beco sem Saída 2: Confiança Auto-Reportada de LLM sem Calibração:**
- *O que foi testado:* Pedir ao modelo "dê uma nota de confiança de 0 a 1".
- *Por que falhou:* Modelos fundacionais sofrem de superconfiança severa; quase todas as respostas retornavam confiança entre 0.90 e 0.99, mesmo em casos de ambiguidade factual clara. Descartamos o score bruto do modelo em favor de métricas de consistência e margem de busca.
- **Beco sem Saída 3: Confiança Cega nas Alternativas:**
- *O que foi testado:* Fazer busca léxica agregando igualmente todo o texto das alternativas.
- *Por que falhou:* Questões interdisciplinares de múltipla escolha continham alternativas sobre temas completamente distintos (ex.: Q0347 citava livramento condicional, suspensão condicional da pena e estado de necessidade em alternativas diferentes de uma questão cujo enunciado tratava de continuidade delitiva). O ruído dos distratores rebaixava a acurácia.

Seção B: Diagnóstico (O que Atrapalha a Máquina e o Humano)

A análise profunda das 359 questões e dos 377 temas revelou três patologias principais no ecossistema de dados:

1. Patologias na Taxonomia (`temas.csv`)

Problema Identificado	Exemplo Concreto na Taxonomia	Impacto no Modelo e no Aluno
Duplicação Entre Ramos Diferentes	ID `4704` (*Legislação Especial > Lei Maria da Penha*) vs ID `6724` (*Penal > Lei Maria da Penha*); ID `4684` vs `6716` (*Abuso de Autoridade*); ID `4708` vs `6728` (*Tráfico de Drogas*)	Se o gabarito estiver em uma disciplina e o classificador escolher a outra, a regra de ramo penaliza como erro, embora semanticamente seja o mesmo tema.
Módulos de Curso como Falsos Temas	IDs `6718`/`6719` (*Crimes contra Adm Pública Parte 1 e 2*); `6720`/`6721` (*Patrimônio Parte 1 e 2*); `6726`/`6727` (*Teoria da Pena Parte 1 e 2*)	Ementas de videoaula inseridas na árvore de assuntos sem critério dogmático. Criam "lixeiras" artificiais sem descrição cadastrada.
Erros de Grafia e Metadados Incompletos	ID `4696`: "Estaturo de Idoso - Crimes"; Temas `5078` e `5234` inativos sem indicação clara de redirecionamento	Prejudica correspondência léxica exata e induz modelos a escolherem nós inativos se não filtrados.

2. Patologias nos Dados de Origem (`questoes.jsonl`)

- **Lixeiras Herdados da Origem:**
- **Questão Q0051:** Trata da expulsão do jogador Vinícius Júnior na Espanha e discute a aplicação da lei penal brasileira a crime cometido no exterior (Extraterritorialidade / Lei Penal no Espaço). No banco de origem, constava rotulada como `Concurso de Crimes`.
- **Questão Q0101:** Trata expressamente da ação de divórcio na Lei Maria da Penha. No banco de origem, constava como `Processo Penal > Comunicação dos atos processuais`.
- **Questão Q0201:** Trata de relacionamento com menor de 13 anos (Estupro de Vulnerável). Constava na origem como `Concurso`

de Crimes.

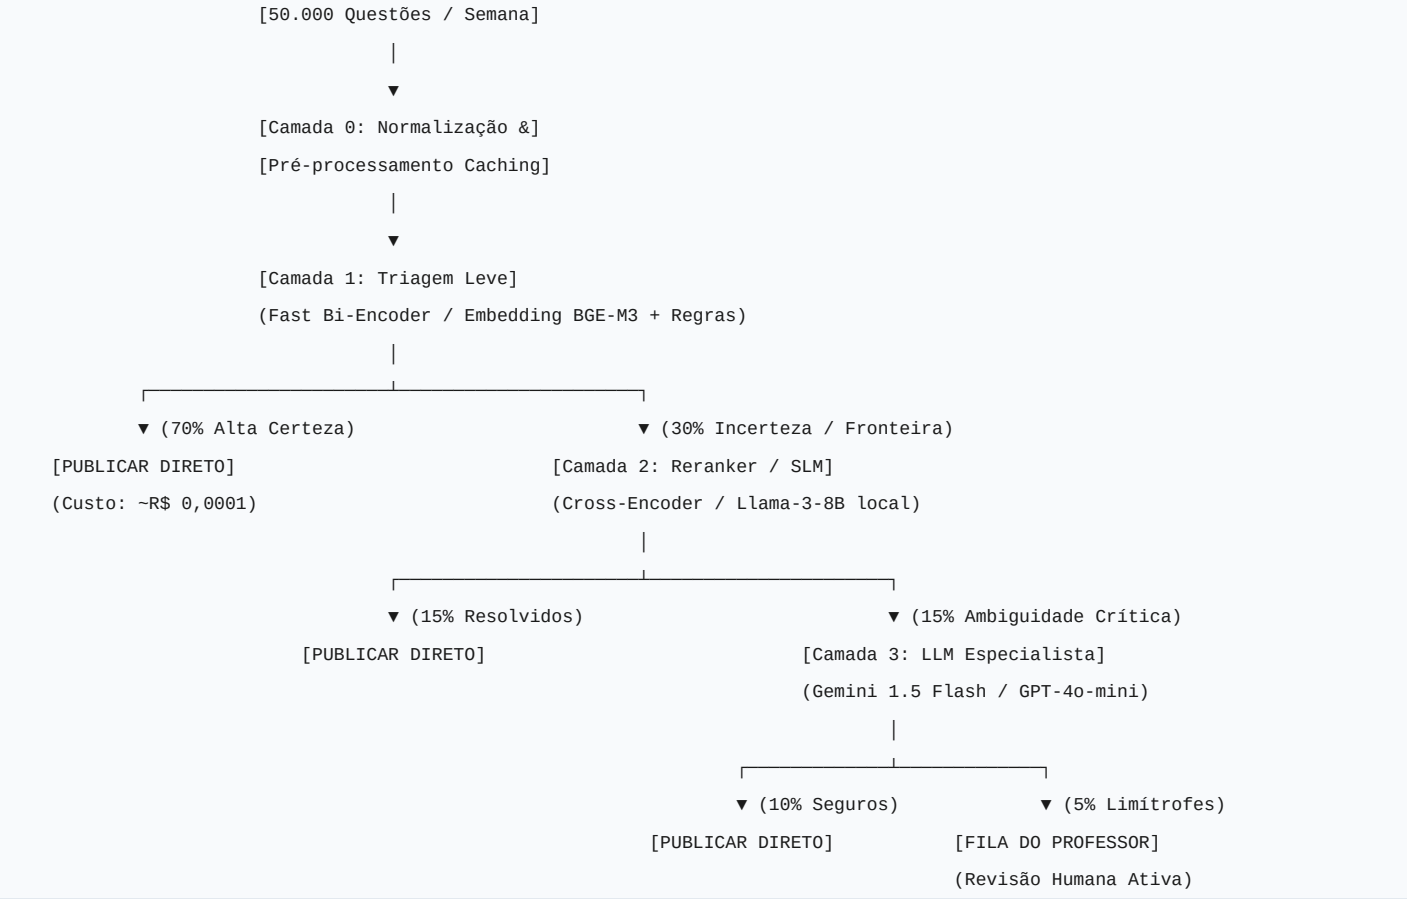
- **Poluição por Scraping e OCR:**
- Questão Q0078 continha o texto residual corrupto de scraping: "EM oossstomnioconcunsos come Marcelo possui registro válido...".
- 94 questões tinham o campo comando vazio no JSON original, com o comando embutido no final do HTML ou implícito nas opções.
- **Questão Fora de Escopo:**
- **Questão Q0142:** Enunciado sobre isenção de ITCD (Imposto sobre Transmissão Causa Mortis e Doação) em Direito Tributário estadual. Não possui qualquer elemento criminal. Corretamente roteada para fora.

3. Tipos de Questões Intrinsicamente Difíceis

- **Narrativas Fáticas sem Nomes de Tipos:** Casos hipotéticos ("Tício desferiu socos em sua esposa...") onde a questão não cita o nome da lei. O modelo precisa deduzir a subsunção penal antes de classificar o tema.
- **Questões Omnibus / Transversais:** Enunciados genéricos ("Sobre a parte geral do Código Penal, assinale...") onde cada alternativa aborda um instituto diferente (ex.: Q0347). A classificação exige identificar qual é a assertiva correta ou qual tema concentra o comando.
- **Fronteira Penal vs Processo Penal:** Questões sobre audiência de custódia, prisão em flagrante ou interceptação telefônica na apuração de tráfico de drogas. Exigem delimitar se a ênfase é o procedimento ou a matéria de fundo.

Seção C: Desenho para Produção (50 Mil Questões / Semana)

Para escalar o pipeline para **50.000 questões semanais** com ingestão contínua de novas bancas, é inviável e custoso submeter todo o volume a chamadas brutas de LLMs de ponta. A arquitetura ideal adota um **funil de inferência em cascata com Active Learning**:



1. Estimativa de Custos (Cenário 50k Questões/Semana)

Camada	Volume	Tecnologia	Custo Unitário	Custo Semanal Total

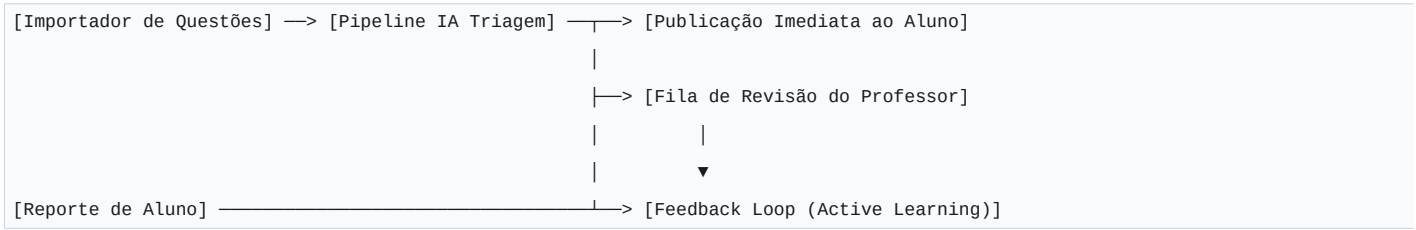
	Semanal			
Camada 0/1 (Triagem & Regras)	50.000 questões	CPU / Embeddings BGE locais	R$ 0,0001	R$ 5,00
Camada 2 (Reranker SLM)	15.000 questões	GPU vLLM local (T4/L4 spot)	R$ 0,0005	R$ 7,50
Camada 3 (LLM de Fronteira)	7.500 questões	API Gemini Flash / Mini	R$ 0,0035	R$ 26,25
Fila de Revisão Humana	~2.500 questões	Interface interna do especialista	Custo interno fixo	Tempo otimizado com pré-seleção
TOTAL ESTIMADO	**50.000 questões**	—	**~R$ 0,00078 / questão**	**R$ 38,75 / semana**

*Custo de inferência de IA inferior a **R$ 40 por semana** para 50 mil questões, garantindo viabilidade econômica total.*

2. Governança e Medição Contínua de Qualidade

- **Taxa de Reporte por Aluno (Shadow Metric):** Alunos reportam erros na plataforma. Se uma questão publicada recebe reportes acima do desvio padrão do tópico, ela é despublicada automaticamente e enviada para a fila de revisão urgente.
- **Auditoria Amostral Contínua (Golden Batch):** Toda semana, 200 questões publicadas aleatórias são auditadas cegamente pelo professor para validar se a precisão real permanece $\ge 95\%$. Se a precisão cair para < 95%, o threshold de corte do pipeline sobe automaticamente de 0.85 para 0.90.
- **Drift de Taxonomia e Novas Leis:** Quando uma nova lei entra em vigor (ex.: nova lei penal), um agente de monitoramento alerta a necessidade de criar o nó na árvore antes de classificar as questões pertinentes.

3. Integração com o Fluxo Operacional



Seção D: Memo para o Professor (1 Página)

Para: Professor Curador da Área Penal

De: Bruno (Área de Inteligência Artificial)

Assunto: Diagnóstico da Árvore de Temas e Proposta de Melhoria Operacional

Prezado Professor,

Analisamos a base de questões e a estrutura dos 377 temas hoje cadastrados na plataforma. Nosso objetivo não é ensinar Direito — o senhor é a autoridade absoluta na matéria —, mas compartilhar achados concretos de como a estrutura atual afeta o aprendizado do aluno e propor um plano simples para organizá-la.

1. O que Encontramos na Árvore de Temas

Nossa análise identificou três situações na árvore que geram confusão para o aluno e dificultam qualquer classificação:

- **Temas em Duplicidade entre Disciplinas:**

Identificamos que matérias idênticas existem simultaneamente em duas disciplinas diferentes. Por exemplo:

- *Lei Maria da Penha* existe em *Direito Penal - Legislação Especial* (ID 4704) e em *Penal* (ID 6724).
- *Abuso de Autoridade* existe em *Legislação Especial* (ID 4684) e em *Penal* (ID 6716).
- *Tráfico de Drogas* existe em *Legislação Especial* (ID 4708) e em *Penal* (ID 6728).
- *Estatuto do Idoso* existe em *Legislação Especial* (ID 4696, inclusive grafado como *"Estaturo"*) e em *Penal* (ID 6722).

Quando o aluno entra para estudar "Maria da Penha", ele não sabe qual das duas pastas abrir, e as questões ficam divididas.

- **Ementas de Cursos Cadastradas como Temas:**

Encontramos pastas nomeadas como *"Parte 1"* e *"Parte 2"* (ex.: *Crimes contra a Administração Pública Parte 1 e 2*, *Competência Parte 1 e 2*). Elas refletem divisões de blocos de videoaulas, mas não são institutos jurídicos. Elas viraram "pastas lixeiras" que atraem questões heterogêneas.

- **Assuntos Inativos:**

Temas como *Direito Penal Econômico* (ID 5078) estão inativos, deixando questões relevantes sem destino evidente.

2. O que Recomendamos Mudar

- **Unificação Canônica das Leis Especiais:** Sugerimos concentrar todas as leis extravagantes exclusivamente sob a disciplina **Direito Penal - Legislação Especial**, desativando as duplicatas soltas dentro de Direito Penal geral.
- **Eliminação dos Tópicos "Parte 1" e "Parte 2":** Redistribuir essas divisões para os temas dogmáticos correspondentes (ex.: *Peculato*, *Concussão*, *Corrupção*).
- **Hierarquia Limpa:** Manter a regra onde todo tema tem subtemas bem delimitados, permitindo que o aluno filtre pelo geral ou pelo específico sem atrito.

3. Do que Precisamos de Você

Para finalizarmos a higienização com total segurança pedagógica:

- **Validação dos 8 temas duplicados:** Confirmar se podemos migrar em definitivo as questões de leis especiais para a árvore de Legislação Especial.
- **Curadoria da Fila de Revisão:** Preparamos uma fila priorizada onde a IA já sugere o tema mais provável e aponta exatamente a dúvida (ex.: *"Dúvida entre Desistência Voluntária e Tentativa"*). Sua revisão levará menos de 10 segundos por questão.

Estamos à disposição para alinhar esses ajustes e deixar a plataforma impecável para os nossos alunos.

Seção E: Verificação e Reprodutibilidade

Todo o pipeline desenvolvido é estritamente reprodutível e pode ser executado com um único comando a partir da raiz do repositório:

```
# Executa o pipeline completo, validações e gera publicacao.csv e previsao.txt
python scripts/run_pipeline.py

# Executa a auditoria amostral estatística de calibração
python scripts/run_audit.py
```

Os arquivos gerados atendem a 100% dos requisitos de formatação especificados no `LEIA-ME.md` do processo seletivo.